

웹크롤링 데이터 기반 딥러닝 감성 분석

도서 리뷰 감성 분석 서비스

리뷰를 입력하면 → 긍정 · 중립 · 부정 자동 분류

긍정

중립

부정

BiLSTM(딥러닝) 모델 + Streamlit 웹앱

YES24 · Goodreads · Watcha 3개 사이트 · 리뷰 41만 건 학습

데이터 수집



딥러닝 학습



웹 서비스

2026. 06. 23.

2503110166 김채우

01	데이터 준비	
02	문제 ① 라벨 불균형	핵심
03	문제 ② 영어 데이터 처리	핵심
04	모델 구조	
05	성능 평가	
06	문제 ③ 과적합	핵심
07	서비스 시연	
08	정리	

★ 문제 ①②③ 해결 과정이 발표의 핵심

데이터 준비

수집한 데이터 — 3개 사이트, 총 41만 건

- **YES24** 한국어 리뷰 42,890건 · 별점 1~10점 → 학습 + 예측
- **Goodreads** 영어 리뷰 270,414건 · 별점 1~5점 → 번역 후 학습 + 예측
- **Watcha** 한국어 리뷰 105,185건 · 별점 없음 → 예측 전용

별점이 있는 YES24·Goodreads는 '학습'에, 별점 없는 Watcha는 '예측'에만 사용합니다.

별점 → 정답(긍/중/부) 변환 규칙

· 모델 학습엔 정답이 필요 → 별점을 긍정/중립/부정으로 변환했습니다.

YES24 (1~10점) : 1~4 부정 5~7 중립 8~10 긍정
 Goodreads (1~5점) : 1~2 부정 3 중립 4~5 긍정

문제 ① — 라벨 불균형


문제

- 별점을 긍/중/부 정답으로 변환했는데
- YES24가 긍정 93%로 극심하게 쏠림
(부정 736 / 중립 2,303 / 긍정 39,841)
- 이대로면 '무조건 긍정'만 찍는 모델

해결

- Watcha(별점 없음)는 학습 제외 → 예측 전용
- Goodreads로 부정·중립 데이터 보강
- class_weight: 적은 클래스에 가중치
부정 ×1.27 중립 ×1.51 긍정 ×0.65

YES24 라벨 분포 — 긍정으로 쏠림



문제 ② — 영어 데이터와 전처리

문제

- Goodreads 27만 건이 전부 영어
→ 한국어 모델이 못 읽음
- 이모지·특수문자·숫자 등 노이즈
- 형태소 분석 30만 건 = 19분 소요


해결 — 데이터 처리 4단계

- ① 영어 → 한국어 번역 (Helsinki NMT)
- ② 한글만 남기고 정제
- ③ 중복 제거
- ④ Okt 형태소 분석 → 캐시 저장
(재실행 시 19분 → 즉시)

데이터 건수 변화



모델 구조



딥러닝(DL) 구간

머신러닝 전처리

한 줄 요약

단어를 벡터로 바꾸고(Embedding), 문장을 앞·뒤로 읽어(BiLSTM) 문맥을 이해한 뒤 3개 감성으로 분류.

· 파라미터 약 650만 개

왜 BiLSTM?

- 리뷰는 '순서'가 중요한 글
예) '재미없지 않다' ↔ '재미 없다'
- 앞뒤 문맥을 함께 봐야 정확
- 한국어는 형태소로 쪼개(Okt) 학습

성능 평가

테스트 정확도

57.2%

- 긍정/중립/부정 3개 분류 문제
- 무작위로 찍으면 33% → 57.2%
- 테스트 21,344건 기준


감성별로 얼마나 맞혔나

● 긍정	실제 긍정 리뷰의 62% 를 맞힘	잘 맞혀요
● 부정	실제 부정 리뷰의 55% 를 맞힘	보통이에요
● 중립	실제 중립 리뷰의 49% 만 맞힘	가장 어려워요

왜 '중립'이 가장 어려울까?

중립은 긍정도 부정도 아닌 '애매한' 감정이라, 모델도 사람도 헷갈립니다.
 그래서 중립 리뷰가 긍정이나 부정으로 잘못 분류되는 경우가 많습니다.
 → 반대로, 칭찬·비판이 분명한 긍정 리뷰는 비교적 정확하게 맞힙니다.

문제 ③ — 과적합




문제

- 학습을 반복할수록 검증 오차가 상승
→ 과적합 (정답을 외워버림)
- 별점 기반 라벨이라 노이즈도 있음
(별점 3점이 꼭 중립은 아님)

해결 / 검증

- EarlyStopping → 가장 좋은 시점 모델 저장
- 검증: 예측이 실제 별점과 맞나?
예측 긍정의 실제 평균 별점 9.49점
예측 부정의 실제 평균 별점 3.34점
→ 감성 '방향'은 정확히 학습됨

서비스 시연



서비스에선 다시 학습하지 않음 — 저장된 모델로 '예측'만 (빠름)

기능

- ① 리뷰 한 개 분석
감성 + 신뢰도 + 확률 막대
형태소 분석 결과까지
- ② 여러 개 한번에 (CSV 업로드)
분포 차트 + 결과 다운로드
- ③ 예시 버튼으로 즉시 체험

실행 방법

- run_sentiment_app.bat 더블클릭
(= streamlit run sentiment_app.py)
- 사용한 모델 파일 (model_3class/)
 - sa_3class_model.keras
 - sa_3class_tokenizer.pkl
- ▶ 지금 실제로 띄워 보겠습니다

정리

문제 → 해결

• 영어 데이터 27만 건	→ 한국어로 번역	학습 데이터 확보
• 긍정 93% 쏠림	→ <code>class_weight</code> + 데이터 보강	소수 클래스 학습
• Watcha 별점 없음	→ 예측 전용으로 활용	10만 건 추가 분석
• 과적합	→ <code>EarlyStopping</code>	최적 모델 유지
• 형태소 분석 19분	→ 결과 캐싱	재실행 즉시

한계

- 한글 전용 (영어는 번역 의존)
- 정확도 57% — '중립'이 특히 어려움
- 별점 기반 라벨이라 노이즈

향후

- KoBERT 등 사전학습 모델로 정확도 ↑
- 사람이 단 라벨로 노이즈 감소
- '중립' 기준 재정의
- 실시간 크롤링 → 자동 분석